



Evaluación de Mecanismos de Seguridad en Grandes Modelos de Lenguaje

Análisis multilingüe de alignment ante prompts tóxicos
Marco Guzmán Vizcarra · Emanuel Martínez Moreno · César Alessandro Barragán Osuna
Licenciatura en Inteligencia Artificial y Ciencia de Datos · Universidad de Guadalajara



1. Introducción y Objetivos

Este trabajo analiza cómo responden distintos LLMs ante prompts tóxicos en inglés y español, evaluando la consistencia de sus mecanismos de seguridad entre idiomas y plataformas.

Pregunta central: ¿El alignment depende del idioma o del proveedor del modelo?

2. Contribuciones

- Pipeline reproducible de auditoría multilingüe
- Evaluación estadística de alignment EN/ES
- Integración de LLM-as-a-Judge
- Comparativa cross-platform de guardrails

3. Pipeline de Datos e Ingeniería NoSQL




Figure: Flujo de Ingesta, Filtrado y Enriquecimiento

Pipeline de procesamiento sobre 2.29 GB de datos semi-estructurados en MongoDB.

- ***Detoxify:** filtrado de prompts tóxicos (≥ 0.3)
- **LLM-as-a-Judge:** clasificación automática de cumplimiento/rechazo usando Mistral Small
- **Corpus final:** 431 muestras validadas

4. Clasificación Supervisada

Métricas cuantitativas globales de los clasificadores supervisados entrenados sobre el espacio vectorial continuo (TF-IDF con 1000 componentes):

Modelo de Clasificación	Accuracy
Naive Bayes (Multinomial)	67.8%
K-Nearest Neighbors (KNN)	65.5%
Regresión Logística	75.0%

Table: Accuracy de clasificadores supervisados

- Mejor modelo: Regresión Logística (75.0%)

5. Distribución del Espacio Vectorial (PCA)

- Alta superposición entre clases
- Corpus desbalanceado (275 vs 156)
- Separación limitada en el espacio vectorial

Esto explica el mejor desempeño relativo de la Regresión Logística.




Figure: Proyección PCA (2D) de los vectores TF-IDF de las respuestas

6. Análisis por Idioma

Evaluación de cumplimiento ante prompts tóxicos aplicando pruebas de independencia Chi-cuadrada (χ^2):

- **Inglés:** 67.8% de cumplimiento
- **Español:** 67.8% de cumplimiento
- **Estadístico de Prueba:** $\chi^2 = 0.11$ — **Valor p:** 0.946




Figure: Distribución χ^2 y zona de aceptación

- No se encontró evidencia significativa de sesgo lingüístico

7. Discusión Narrativa

- Los mecanismos de alignment dependen de políticas corporativas
- Se observó simetría EN/ES pero variabilidad entre plataformas
- La seguridad en IA generativa sigue siendo un problema abierto y no estandarizado

Mini-Glosario

- **Alignment:** Capacidad de un LLM para seguir políticas de seguridad.
- **Guardrails:** Restricciones que limitan respuestas dañinas.
- **Multilingual Jailbreak:** Técnicas para evadir defensas usando distintos idiomas.
- ***Detoxify:** Clasificador pre-entrenado para detección de lenguaje tóxico.

El alignment mostró consistencia entre idiomas, pero diferencias significativas entre plataformas.

8. Variabilidad de Alignment entre Plataformas y Conclusiones

Hallazgo principal

- No se detectó sesgo significativo EN vs ES
- Sí se observaron diferencias significativas entre plataformas


Interpretación

- Gemini mostró políticas más restrictivas
- ChatGPT priorizó mayor cumplimiento de instrucciones

Trabajo futuro

- Evaluar idiomas de bajos recursos
- Analizar vulnerabilidad ante multilingual jailbreaks

Rechazo de Prompts Tóxicos por Plataforma



mayor porcentaje = mayor rechazo de solicitudes tóxicas