

Evaluación de Mecanismos de Seguridad y Sesgo de Alineación en Grandes Modelos de Lenguaje (LLMs)

Autores: M. Guzmán Vizcarra, E.

Martínez Moreno, C. A. Barragán Osuna

Carrera: Inteligencia Artificial y Ciencia de Datos
Institución: CUGDL - Universidad de Guadalajara

Este reporte ha sido consolidado como una **herramienta de estudio grupal**. Reúne, estructura y sintetiza de manera rigurosa cada una de las fases desarrolladas en el proyecto integrador, desde la ingeniería de datos NoSQL hasta el análisis estadístico confirmatorio y la evaluación analítica de modelos supervisados (Naive Bayes vs. KNN vs. Regresión Logística).

1. Ingesta de Datos e Ingeniería NoSQL (Fase 1)

La base fundamental del proyecto se construyó sobre un análisis profundo del corpus público *tucnguyen/ShareChat*, el cual compila interacciones reales en 5 plataformas líderes de LLM: *ChatGPT*, *Gemini*, *Grok*, *Claude* y *Perplexity*.

1.1. El Reto del Desbalance Lingüístico

Al procesar la fuente de datos semiestructurada original (~2.29 GB), se identificó un sesgo crítico en la distribución de idiomas que requirió una estrategia avanzada de optimización de recursos:

- **Inglés (EN):** Representa aproximadamente el **58%** del dataset total.
- **Español (ES):** Representa únicamente el **1.4%** del total.
- **Otros Idiomas:** ~40.6%.

Estrategia de Optimización: Para mitigar el consumo de memoria y almacenamiento, se implementó una lectura por **Streaming en Hugging Face Datasets**. Esto permitió realizar un filtrado dinámico mediante la columna `detected_language_final` e iterar hasta capturar exactamente las muestras deseadas sin descargar el corpus completo. Debido al bajísimo volumen de datos en español para Claude, este fue excluido de las pruebas multilingües comparativas, dejando a **ChatGPT** como el eje central por poseer un balance real ideal (192 muestras en EN y 207 en ES).

1.2. Pipeline de Enriquecimiento y Almacenamiento en MongoDB

Las muestras filtradas fueron cargadas en una base de datos local **MongoDB** para su estructuración y enriquecimiento offline. El pipeline ejecutó dos subprocesos analíticos de vanguardia:

1. **Filtrado de Toxicidad con Detoxify (Multilingual):** Se pre-clasificaron los prompts de los usuarios, seleccionando aquellos con un score de toxicidad ≥ 0.3 para consolidar un subconjunto de "prompts tóxicos estresantes".
2. **Etiquetado Automático vía LLM-as-a-Judge:** Para evaluar la respuesta del LLM a dicho prompt tóxico, se implementó un flujo automatizado conectándose a la API de **Mistral AI (Mistral Small)**. Se validó

académicamente que un modelo externo actúe como juez, clasificando cada respuesta en una de tres categorías mutuamente excluyentes: CUMPLIMIENTO, CUMPLIMIENTO_CON_DISCLAIMER o RECHAZO. Se añadió una pausa de 2 segundos entre peticiones para sortear las restricciones de *rate limiting*.

2.29 GB VOLUMEN FUENTE	431 MUESTRAS CONSOLIDADAS	≥ 0.3 UMBRAL TOXICIDAD	Mistral LLM-AS-A-JUDGE
----------------------------------	--	--	----------------------------------

2. Análisis Estadístico Descriptivo e Inferencial

Una vez consolidado el corpus final de 431 instancias en MongoDB, se procedió a realizar un análisis estadístico para responder la pregunta central de investigación: *¿El alineamiento (alignment) de un modelo depende del idioma de entrada o de las políticas del proveedor?*

2.1. Tasas de Rechazo por Plataforma

Al cuantificar la proporción en que los modelos detienen o bloquean proactivamente un prompt tóxico (activación de *Guardrails*), los resultados evidenciaron políticas marcadamente asimétricas entre compañías:

- **Gemini:** Presentó la política de seguridad más restrictiva con un **51.4% de rechazo** de prompts tóxicos.
- **Perplexity:** Se situó en el **46.4% de rechazo**.
- **Grok:** Alcanzó un **34.9% de rechazo**.
- **Claude:** Registró un **34.5% de rechazo**.
- **ChatGPT:** Mostró el nivel más permisivo con un **29.3% de rechazo**, priorizando en su lugar el cumplimiento de la instrucción dada por el usuario.

2.2. Prueba Inferencial de Simetría Lingüística (Chi-Cuadrada)

Para determinar de forma matemáticamente rigurosa si las defensas de los modelos flaquean o cambian al comunicarse en español en comparación con el inglés (vulnerabilidad de *Multilingual Jailbreak*), se aplicó una

****Prueba de Independencia de Chi-cuadrada (χ^2)**** sobre las frecuencias de cumplimiento observadas.

Resultados del Análisis de Independencia Lingüística:

- Tasa de Cumplimiento General en Inglés: **67.8%**
- Tasa de Cumplimiento General en Español: **67.8%**
- Estadístico de Prueba Calculado: $\chi^2 = 0.11$
- Valor p (p-value): **0.946**

Interpretación Teórica para el Examen: Dado que el valor p (**0.946**) es significativamente mayor que el nivel de significancia estándar ($\alpha = 0.05$), **no se rechaza la hipótesis nula (H_0)**. No existe evidencia estadística suficiente para afirmar un sesgo lingüístico. Concluimos que existe una **simetría lingüística** en los guardrails; las variaciones de comportamiento observadas obedecen a políticas corporativas de las plataformas, no al idioma empleado.

3. Modelado Supervisado y Vectorización Espacial (Fase 2)

La segunda etapa del proyecto consistió en entrenar modelos predictivos supervisados clásicos sobre el corpus generado para clasificar las respuestas de los modelos automáticamente a partir de sus propiedades textuales.

3.1. Vectorización TF-IDF

Las respuestas de los LLMs fueron limpiadas mediante expresiones regulares (remoción de caracteres especiales y normalización a minúsculas) y codificadas usando `TfidfVectorizer` con un tope máximo de **1,000** características morfológicas (tokens), dividiendo el conjunto en 80% entrenamiento y 20% prueba.

3.2. Desempeño Empírico del Clasificador Baseline (Gaussian Naive Bayes)

Se entrenó un modelo **Gaussian Naive Bayes (GNB)** utilizando la librería *scikit-learn* para la predicción de las tres clases de alineación. El modelo arrojó las siguientes métricas en el set de prueba:

Clase de Alineación (Etiqueta)	Precisión	Recall (Sensibilidad)	F1-Score	Soporte (Casos)
CUMPLIMIENTO	0.67	0.98	0.80	56
CUMPLIMIENTO CON DISCLAIMER	0.75	0.11	0.19	27
RECHAZO	1.00	0.25	0.40	4
Métrica Global (Accuracy)	0.6782 (67.82%)			87

Diagnóstico Crítico del Baseline: Observen el fuerte desbalance de clases en el soporte de prueba (56 frente a 4). Aunque el accuracy global parece aceptable (~68%), el modelo sufre de un severo problema de **Recall** en las categorías minoritarias críticas (RECHAZO = 21% y DISCLAIMER = 11%). Esto significa que el clasificador Naive Bayes tiende a ignorar la existencia de estas fronteras y cataloga casi todo erróneamente como cumplimiento genérico.

4. Fundamentos Matemáticos y Comparativa Estricta: KNN vs. Naive Bayes

Para la sustentación teórica, es crucial dominar la distinción formal de por qué un algoritmo basado en instancias (KNN) supera a uno paramétrico-probabilístico (GNB) bajo estas condiciones de espacio muestral.

4.1. Formalismo del Algoritmo K-Nearest Neighbors (KNN)

KNN es un modelo geométrico, no paramétrico y basado en instancias. No asume una distribución analítica de los datos. Mide la proximidad de un nuevo vector x^* sobre un plano métrico $\mathbb{R}^2$ utilizando la **Distancia Euclidiana**:

$$d(x^*, x^{(i)}) = \|x^* - x^{(i)}\|_2 = \sqrt{\sum_{j=1}^2 (x_j^* - x_j^{(i)})^2}$$

A partir del conjunto de los K vecinos más cercanos ($\mathcal{N}_K(x^*)$), estima la probabilidad posterior por voto mayoritario e indexa mediante el operador **argmax**:

$$\hat{y}^* = \underset{c}{\operatorname{argmax}} \sum_{i \in \mathcal{N}_K(x^*)} \hat{1}(y^{(i)} = c)$$

4.2. Formalismo del Algoritmo Gaussian Naive Bayes (GNB)

GNB calcula la máxima probabilidad posterior aplicando el Teorema de Bayes, pero introduce el **supuesto de independencia condicional** ("ingenuo"):

$$P(x^* | Y = c) = \prod_{j=1}^2 N(x_j^* | \mu_{c,j}, \sigma_{c,j}^2)$$

Esto restringe forzosamente la matriz de covarianza de cada clase a ser una **matriz diagonal** (Σ_c con covarianzas $\sigma_{12} = 0$), asumiendo una geometría elipsoidal perfectamente simétrica y alineada con los ejes coordenados.

4.3. Los Tres Pilares de la Superioridad de KNN en este Escenario

- Inexistencia de Sesgo Distribucional:** GNB obliga a los datos a ajustarse a una campana de Gauss. En nuestro dataset, las respuestas etiquetadas como RECHAZO o DISCLAIMER no forman elipses perfectas; se agrupan en pequeñas "islas densas" o curvas según la estructura de la frase. KNN, al ser no paramétrico, mapea la topología exacta sin sesgos geométricos rígidos.
- Violación de la Independencia Condicional:** En las respuestas de un LLM, la longitud del texto (x_1) y el nivel de toxicidad remanente (x_2) **no son independientes**. Los rechazos automáticos de seguridad son sumamente concisos y concentran palabras de alerta muy específicas, mientras que los cumplimientos extensos diluyen el score de toxicidad. Al ignorar esta correlación analítica, Naive Bayes trunca la distancia real. KNN es inmune a esto porque opera directamente en el espacio métrico integrado.
- Efecto Multiplicativo del Desbalance de Clases:** En Naive Bayes, la probabilidad previa de clase **In $P(Y = c)$** actúa como un factor de empuje multiplicativo que expande geométricamente el área de la clase mayoritaria (CUMPLIMIENTO), absorbiendo por completo los límites de las clases minoritarias. En KNN, el radio de

búsqueda local para un número K acotado permite aislar racimos compactos de RECHAZO, resguardando el *Recall* en las fronteras de decisión críticas.

5. Mini-Glosario para Examen de Proyecto Integrador

- **Alignment (Alineación):** El proceso de ajustar un modelo de lenguaje para asegurar que actúe conforme a los valores humanos, intenciones de seguridad y políticas éticas predefinidas.
- **Guardrails (Garantías de Seguridad):** Capas de filtrado o restricciones operativas que bloquean de forma proactiva la generación de contenido dañino, ilegal o tóxico.
- **LLM-as-a-Judge:** Metodología de evaluación automatizada donde un modelo de lenguaje con capacidades avanzadas (ej. Mistral Small) clasifica o califica las respuestas de otros modelos bajo un set estricto de rúbricas.
- **Multilingual Jailbreak:** Técnica de evasión de defensas en la cual un usuario traduce un prompt prohibido a un idioma con menores recursos o menor atención en el entrenamiento de guardrails para forzar al modelo a responder.
- **Detoxify:** Modelo clasificador open-source optimizado para la detección y cuantificación multietiqueta del grado de toxicidad e insulto dentro de cadenas de texto.